

Er reproduserbarhet nok?

Katrine Bårdsen

Tuesday 15 Sep, 2026

Abstract Et kort sammendrag, en til to avsnitt.

Introduksjon

Vitenskapelig fremgang er basert på pålitelige oppdagelser, samt tillit. For å kunne bygge videre på tidligere arbeid er det viktig at undersøkelser er gjennomført med høy metodisk kvalitet og at resultatene er etterrøvbare. For å oppnå tillit til vitenskapelige konklusjoner er det å kunne gjenskape et eksperiment en viktig tilnærming. Likevel har forskningsverden blitt svekket av rapporter som nylig har oppdaget at en urovekkende andel av fagfellevurderte studier ikke lar seg reprodusere (McNutt, 2014).

Denne artikkelen undersøker om reproduserbarhet bør være et minimiskrav for publisering (Peng, 2011) eller om forskningsfellesskapet må kreve full replikerbarhet. Artikkelen tar utgangspunkt i National Science Foundation (NSF) som definerer robust og pålitelig vitenskap gjennom tre begreper - reproduserbarhet, replikerbarhet og generaliserbarhet. Videre kommer Goodman et al. (2016) med en mer presis forklaring på reproduserbarhet, ved å skille mellom metoders reproduserbarhet og resultatenes reproduserbarhet.

Artikkelen diskuterer utfordringene knyttet til replikerbarhet og reproduserbarhet, med publikasjonsskjeivhet og type 1-feil (falske positiver) som hovedfokus. Det redegjøres for ulike tilnærminger som kan bidra til å håndtere og løse replikasjonskrisen. Avslutningsvis drøftes det hvordan moderne verktøy kan hjelpe til å sikre metodisk reproduserbarhet.

Det er viktig å ha kunnskap om dette temaet ettersom upålitelig forskning kan få alvorlige konsekvenser. Falske positiver er kanskje den mest kostbare feilen. Falske positiver refererer til den feilaktige forkastningen av nullhypotesen. Dette fører til sløsing av ressurser, uensiktsmessig policy og det svekker troverdigheten til vitenskapen (Simmons et al., 2011).

Litteraturgjennomgang

Teori og begreper

Vitenskapelig fremgang er basert på pålitelige oppdagelser (McNutt, 2014). Robust og pålitelig vitenskap er dermed fundamentet for utviklingen i vitenskapen. Det har likevel vært uklarhet om hva dette begrepet faktisk innebærer. National Science Foundation (NSF) har dermed definert «robust og pålitelig vitenskap» gjennom tre krav, den må være reproduserbar, replikerbar og generaliserbar.

NSF definerer reproduserbarhet som evnen til å duplisere resultater ved bruk av samme data og prosedyrer. Replikerbarhet innebærer at man oppnå samme konklusjon og resultat ved å bruke samme prosedyrer, men med nye data. Jasny et al. (2011) hevder at replikerbarhet regnes som den vitenskaplige gullstandarden, der reproduserbarhet anses som nødvendig, men ikke tilstrekkelig forutsetning for replikerbarhet. Generaliserbarhet vil si at resultatene av en studie gjelder i en ny sammenheng, ved bruk av data i annen kontekst eller populasjoner som skiller seg ut fra den originale studien. I sammenheng med beregningsvitenskap, diskuterer Peng (2011) om teknisk reproduserbarhet bør være et minstekrav for publisering.

Flere har prøvd å definere begrepet reproduserbarhet mer presis. Blant annet har Goodman et al. (2016) foreslått å definere begrepet ved å skille mellom metoders reproduserbarhet og resultatenes reproduserbarhet. Metoders reproduserbarhet refererer til tilstrekkelig detaljert metodikk slik at de samme prosedyrene kan gjentas nøyaktig. Reproduserbarhet av resultater innebærer å oppnå like resultater fra en uavhengig studie. Goodman et al. (2016) knytter også dette til robusthet som refererer til stabiliteten eksperimentelle konklusjoner ved variasjon i forutsetninger eller prosedyrer. For at reproduserbarhet skal kunne etterprøves i praksis, fremhever Piwowar et al. (2018) at fri tilgang til data, publikasjoner og kjeldekoder gjennom åpen vitenskap er en nødvendig forutsetning.

Systematiske problemer

Publikasjonsskjevhet der, sannsynligheten for at en studie publiseres er basert på resultat, er en av hovedårsakene til at ikke-reproducerbare funn vokser i faglitteraturen. Det viser seg å være publisert svært få studier med negative konklusjon der man ikke kan forkaste nullhypotesen .

Ved å benytte signifikant på 5% aksepterer forskere at 1 av 20 studier, helt tilfeldig, vil forkaste nullhypotesen og gi en type 1-feil. Forskningsverden gjennomfører utallige studier og tester. Det som blir et problem er at de få studiene som tilfeldigvis oppnår effekt blir publisert i litteraturen, mens studiene som viser manglene effekt blir liggende i arkivskuffen. Dette beskrev Rosenthal (1979) som «File Drawer Problem». Det gjør at litteraturen fylles med skjeve utvalg, noe som forplanter seg negativt i metaanalyser (Young et al., 2008). Derfor har Iyengar & Greenhouse (1988) drøftet spesifikke teknikker for å håndtere denne skjevheten.

Simmons et al. (2011) hevder at falske positive er den mest kostbare feilen i forskning. Når falske positive først dukker opp i litteraturen er det vedvarende fordi det er skjedd at prestisjefylte tidsskrifter publiserer nullfunn eller replikasjoner. I tillegg sløser falske positive med ressurser og uhensiktsmessig policy. Dette fører til at troverdigheten rundt dette fagfeltet svekkes (Simmons et al., 2011). For å motvirke dette har blant annet Nosek et al. (2015) argumentert for at tidsskrifter må innføre retningslinjer som bidrar til å fremme åpenhet , og økt bruk av forhåndsregistrering. (nosek2018?) understreker at forskere må begrunne sitt valg av signifikansnivå, forskningsdesign og strategier i forkant av datainnsamling.

Replikasjonskrisen

Replikasjonskrisen refererer til den økende bekymringen i vitenskapsverden om at en urovekkende andel av fagfelleverderte studier ikke lar seg gjenskape når uavhengige forskere forsøker å gjenta disse. Replikasjonskrisen startet inne psykologi, men spredte seg til andre fagfelt innenfor vitenskapen. Ioannidis (2005) viste teoretisk at de fleste publiserte forskningsfunn kan være falske. Nosek et al. (2015) organiserte et omfattende prosjekt som underbygget

dette. Prosjektet gikk ut på at forskere prøvde å replikere 100 studier fra . Resultatet viste at selv om 97% av de opprinnelige studiene hadde signifikante funn, var det bare 36% av replikasjonsforsøkene som klarte å oppnå samme resultat. I oppfølgingsstudien «Many labs 2» fant Klein et al. (2018) at bare 15 av 28 klassiske studier, det vil si omtrent 54%, var lot seg replikere.

Kriserapportene startet i psykologi, men spredte seg raskt til andre fagfelt. I økonomifaget avdekket JMCB-prosjektet at det bare var mulig å oppnå full reproduserbarhet i 2 av over 70 produserte artikkler, når forfatterne brukte egne datasett. Hovedgrunnen var feil i kildekode, manglende data og utilstrekkelig dokumentasjon. McCullough et al. (2008) argumenterte for at krav om dataarkiv i seg selv sjelden er nok til å sikre reproduserbar forskning.

(mar?) viser hvordan skript, rådata og rapporter kan samles inn i et dynamisk «research compendium» i R slik at reproduserbarhet kan gjennomføres i praksis. Som et konkret eksempel på bruk av åpen offentlige data og reproduserbare modeller i datavitenskap benytter inspeksjonsdata fra APHIS med ca. 2,7 millioner forsendelser for å estimere logit-modeller for invasiv risiko.

Diskusjon av forskningsspørsmålet (problemstillingen)

Burde replikerbarhet være et krav eller er det å be om for mye?

Peng (2011) argumenterte for at reproduserbarhet bør anses som et grunnleggende minstekrav for publisering av beregningsorientert forskning. Dersom forfatteren ikke kan legge frem data og kildekode som gjenskaper de publiserte tabellene, mangler studien metodisk validitet.

Det å kreve full replikerbarhet før publisering kan derimot være for mye å be om. Innsamling av data kan kreve mye tid og enorme ressurser, det kan i noen tilfeller også være umulig. En studie kan være 100 % reproduserbar, men kan likevel være et resultat av skjevheter i utvalget eller Type 1-feil. Dermed er det ikke garantert at reproduserbare studier har en konklusjon som er sann.

Kan Quarto dokumenter hjelpe med å oppnå reproduserbarhet?

Grunntanken med beregningsbare dokumenter (computable documents) er at datainnlesingen, teksten, modellskriptene og resultatgenerering samles i én og same kildefil. Dette er en eldre idé som blant annet bygger på Donald E. Knuth prinsipper om «literate programming» (Knuth, 1984) og Gentleman & Temple Lang (2003) sitt begrep «compendium», som viser til en beholder som kobler data, kode og tekst sammen i et dynamisk dokument.

Quarto utgjør en oppdatert og mer robust videreføring av R Markdown og R Notebooks og fungerer som en moderne versjon av den tradisjonelle «computable documents». Ved å benytte pandoc som transformer kan et quarto-dokument konverteres direkte til pdf, html, dock og andre formater. Dette eliminerer manuelle feilkilder ved kopiering av tabeller og tall, og sikrer at analysen kan gjennomføres på nytt i detalj.

Et quarto-dokument alene sikrer ikke fullstendig reproduserbarhet over tid dersom det oppstår endringer i det tilhørende beregningsmiljøet. R-pakker er i stadig utvikling, og endringer i pakkeversjon er en årsak til at eldre skript slutter å fungere. En mulig løsning for dette problemet er å benytte verktøyet renv til prosjektet.

Hvilke problem gjenstår og hvordan kan disse løses?

Konklusjon

Noen kloke ord.

Referanser

- Gentleman, R., & Temple Lang, D. (2003). Statistical Analyses and Reproducible Research. *Journal of Computational and Graphical Statistics*, 16(1), 1–23.
- Goodman, S. N., Fanelli, D., & Ioannidis, J. P. A. (2016). What does research reproducibility mean? *Science Translational Medicine*, 8(341), 341ps12–341ps12.
- Ioannidis, J. P. A. (2005). Why Most Published Research Findings Are False. *PLOS Medicine*, 2(8), e124.
- Iyengar, S., & Greenhouse, J. B. (1988). Selection models and the file drawer problem. *Statistical Science*, 3(1), 109–117.
- Jasny, B. R., Chin, G., Chong, L., & Vignieri, S. (2011). Again, and again, and again. *Science*, 334(6060), 1225–1225.
- Klein, R. A., Vianello, M., Hasselman, F., Adams, B. G., Reginald B. Adams, Jr., Alper, S., Aveyard, M., Axt, J. R., Babalola, M. T., Bahník, Š., Batra, R., Berkics, M., Bernstein, M. J., Berry, D. R., Bialobrzeska, O., Binan, E. D., Bocian, K., Brandt, M. J., Busching, R., ... Nosek, B. A. (2018). Many labs 2: Investigating variation in replicability across samples and settings. *Advances in Methods and Practices in Psychological Science*, 1(4), 443–490.
- Knuth, D. E. (1984). Literate Programming. *The Computer Journal*, 27(2), 97–111.
- McCullough, B. D., McGeary, K. A., & Harrison, T. D. (2008). Do economics journal archives promote replicable research? *Canadian Journal of Economics/Revue Canadienne d'économie*, 41(4), 1406–1420.
- McNutt, M. (2014). Reproducibility. *Science*, 343(6168), 229–229.
- Nosek, B. A., Alter, G., Banks, G. C., Borsboom, D., Bowman, S. D., Breckler, S. J., Buck, S., Chambers, C. D., Chin, G., Christensen, G., Contestabile, M., Dafoe, A., Eich, E., Freese, J., Glennerster, R., Goroff, D., Green, D. P., Hesse, B., Humphreys, M., ... Yarkoni, T. (2015). Promoting an open research culture. *Science*, 348(6242), 1422–1425.
- Peng, R. D. (2011). Reproducible Research in Computational Science. *Science*, 334(6060), 1226–1227.
- Piwowar, H., Priem, J., Larivière, V., Alperin, J. P., Matthias, L., Norlander, B., Farley, A., West, J., & Haustein, S. (2018). The state of OA: A large-scale analysis of the prevalence and impact of Open Access articles. *PeerJ*, 6, e4375.
- Rosenthal, R. (1979). *The file drawer problem and tolerance for null results*.
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science*, 22(11), 1359–1366.

Young, N. S., Ioannidis, J. P. A., & Al-Ubaydli, O. (2008). Why Current Publication Practices May Distort Science. *PLoS Medicine*, 5(10), e201.

Appendiks A

- Versjon nummer og referanse til R pakken brukt i dokumentet
- R versjon brukt, med referanse

Appendiks B

- Hvordan er KI brukt
- Husk invitasjon til chat